GSLAformer · 关键机制展开

区分三种注意力的可见范围；规范状态 z、时间 hidden h 与条件融合结果 a 不是同一个坐标

A 残差与归一化骨架

组内 / 时间 / 关系块均为 Post-LN

输入 tokens
空间宽度 32 / 时间宽度 64

Multi-Head Attention
注意力可见域由各分支决定

Add & LayerNorm

Feed Forward
Linear(d→4d) → GELU
→ Dropout → Linear(4d→d)

Add & LayerNorm

输出 tokens
不是直接得到一个组向量

残差支路为原输入；attention / FFN 输出另有 dropout

B 空间信息如何变成状态

组内全连接与关系受限通信是两步，不是同一层

组内注意力 + 摘要 token
同组有效实体可相互读取
摘要参与本层计算，之后剥离

实体拼接 → 关系注意力 ×2
Q 行=接收方；K/V 列=发送方
self + 正向边 + 声明的反向边
每类型 / 方向 / head 可学习 bias

按组切回增强实体
无效实体输出置零
仍保留实体轴 N_g，不提前压成组向量

分组 query cross-attention
Q：每组可学习 query
K/V：空组 token + 增强实体
各动态组独立查询与参数

规范状态 z^g
拼数量 / 覆盖率 → Linear → LayerNorm

C 时间与预测坐标

这里展示实际计算，不按过时文字补不存在的层

系统历史 token
z：192；y：1；总表标记：2
组 coverage / generated：12
日历：4；合计 211 维

联合 Linear(211→64) + 位置
因果时间 attention ×2
h = 最后 token；不另设日历投影

拼 h / c / p_k / lead(k)
64 + 64 + 64 + 16 = 208
Linear → GELU → Dropout → Linear
a[B,64]：双头共享的融合结果

两个并列预测目标
$\hat{y}_k$：1 维；$\hat{z}_k$：6×32 维
状态头末端无额外 LayerNorm

回灌的是规范 $\hat{z}_k$ 和同一 $\hat{y}_k$
不是 h，不是原始实体特征
不更新实体 memory / 静态 c

D 训练与推理分开

原图没有规定训练协议；以下是当前实现的补充，不是原图中的隐含要求

阶段 A：H 步直接负荷监督
表示链可训练；latent 头不进入 loss

→

选择 best_A → 冻结表示
实体 / 空间 / 关系 / 读出 / 静态链

→

阶段 B：自由递推 + latent 辅助
1 → min(3,H) → H；teacher 只用于标签